

卡爾曼增益完整推導教材

主題：從貝氏定理、兩高斯乘積，到矩陣形式卡爾曼增益的逐步推導

語言：繁體中文 | 公式格式：LaTeX Large

適用對象：電機／航空工程、嵌入式系統、無人機軟體開發者

目錄

- 預備知識：高斯分佈的代數性質
- 貝氏定理與最優融合的動機
- 純量推導：兩高斯乘積
 - 3.1 展開乘積
 - 3.2 配方 (Completing the Square)
 - 3.3 辨識卡爾曼增益結構
 - 3.4 三個核心等式的誕生
- 幾何直覺：增益的物理意義
- 推廣到多維矩陣形式
 - 5.1 觀測矩陣 H 的角色
 - 5.2 新息協方差 S
 - 5.3 矩陣卡爾曼增益
- 最小化跡推導 (變分法驗證)
- 五大 KF 方程式統整
- EKF 的增益：非線性推廣
- 比較表格：增益在不同情境下的行為
- 數值範例：一維高度估計

1. 預備知識：高斯分佈的代數性質

1.1 單變數高斯分佈

$$\mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

記憶技巧：高斯分佈由均值 μ (中心位置) 與變異數 σ^2 (寬度/不確定性) 完全決定。

1.2 多變數高斯分佈

對 n 維隨機向量 $\mathbf{x} \in \mathbb{R}^n$:

$$\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}, \mathbf{P}) = \frac{1}{(2\pi)^{n/2} |\mathbf{P}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \mathbf{P}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$

其中 $\mathbf{P}$ 為 $n \times n$ 對稱正定協方差矩陣。

1.3 高斯的四大封閉性質

這四個性質是卡爾曼濾波器能有解析解的根本原因：

性質	陳述	重要性
線性映射封閉	若 $\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \mathbf{P})$ ，則 $\mathbf{Ax} + \mathbf{b} \sim \mathcal{N}(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{APA}^\top)$	狀態預測步驟的基礎
乘積封閉	兩高斯之乘積（歸一化後）仍為高斯	卡爾曼更新的核心
邊際分佈封閉	聯合高斯的邊際分佈仍為高斯	狀態邊際化
條件分佈封閉	聯合高斯的條件分佈仍為高斯	後驗推斷

關鍵結論：若先驗與似然均為高斯，貝氏後驗仍為高斯，且可以**解析地**求出其參數。這個解析解就是卡爾曼濾波器。

2. 貝氏定理與最優融合的動機

2.1 貝氏定理回顧

$$\underbrace{p(x | z)}_{\text{後驗}} = \frac{\underbrace{p(z | x)}_{\text{似然}} \cdot \underbrace{p(x)}_{\text{先驗}}}{\underbrace{p(z)}_{\text{正規化常數}}}$$

在狀態估計的脈絡中：

- 先驗** $p(x)$ ：在新量測到來之前，對狀態的信念（由系統模型傳播而來）
- 似然** $p(z | x)$ ：給定真實狀態 x ，觀測到量測值 z 的機率（由感測器模型決定）
- 後驗** $p(x | z)$ ：融合量測後對狀態的最新信念

2.2 高斯假設下的問題設定

設先驗與似然均為高斯：

$$p(x) = \mathcal{N}(x; \mu_1, \sigma_1^2)$$

$$p(z | x) = \mathcal{N}(z; x, \sigma_2^2) \iff p(z | x) \propto \mathcal{N}(x; z, \sigma_2^2)$$

(第二式成立是因為 $p(z | x)$ 以 x 為自變數時，等同於以 z 為觀測、以 σ_2^2 為不確定性的高斯)

因此後驗正比於：

$$p(x | z) \propto \mathcal{N}(x; \mu_1, \sigma_1^2) \cdot \mathcal{N}(x; \mu_2, \sigma_2^2)$$

其中 $\mu_2 \equiv z$ 為量測值本身。

問題：兩個高斯相乘，結果的均值（最優估計）與變異數（估計不確定性）是多少？

3. 純量推導：兩高斯乘積

3.1 展開乘積

兩個高斯相乘，指數相加（忽略正規化常數）：

$$p_1(x) \cdot p_2(x) \propto \exp \left[-\frac{(x - \mu_1)^2}{2\sigma_1^2} - \frac{(x - \mu_2)^2}{2\sigma_2^2} \right]$$

設乘積後的分佈仍為高斯（待求其參數）：

$$\propto \exp \left[-\frac{(x - \mu_{\text{post}})^2}{2\sigma_{\text{post}}^2} \right]$$

因此只需比較指數部分：

$$\frac{(x - \mu_1)^2}{2\sigma_1^2} + \frac{(x - \mu_2)^2}{2\sigma_2^2} = \frac{(x - \mu_{\text{post}})^2}{2\sigma_{\text{post}}^2} + \text{const} \quad (\text{與 } x \text{ 無關的項})$$

展開左側，收集 x 的各次冪係數：

$$\underbrace{\left(\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}\right) \frac{x^2}{2}}_{x^2 \text{ 係數}} - \underbrace{\left(\frac{\mu_1}{\sigma_1^2} + \frac{\mu_2}{\sigma_2^2}\right) x}_{x^1 \text{ 係數}} + \underbrace{\frac{\mu_1^2}{2\sigma_1^2} + \frac{\mu_2^2}{2\sigma_2^2}}_{x^0 \text{ 係數 (常數)}}$$

3.2 配方 (Completing the Square)

一般形式 $\frac{a}{2}x^2 - bx + c = \frac{a}{2}\left(x - \frac{b}{a}\right)^2 + \left(c - \frac{b^2}{2a}\right)$ ，比對係數：

二次項係數 → 後驗精度 (Precision) 的倒數即為後驗變異數：

$$\frac{1}{\sigma_{\text{post}}^2} = \frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2} = \frac{\sigma_1^2 + \sigma_2^2}{\sigma_1^2 \sigma_2^2}$$

$$\sigma_{\text{post}}^2 = \frac{\sigma_1^2 \sigma_2^2}{\sigma_1^2 + \sigma_2^2}$$

一次項係數 ÷ **二次項係數** → 後驗均值：

$$\mu_{\text{post}} = \frac{b}{a} = \frac{\frac{\mu_1}{\sigma_1^2} + \frac{\mu_2}{\sigma_2^2}}{\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}} = \frac{\sigma_2^2 \mu_1 + \sigma_1^2 \mu_2}{\sigma_1^2 + \sigma_2^2}$$

$$\mu_{\text{post}} = \frac{\sigma_2^2 \mu_1 + \sigma_1^2 \mu_2}{\sigma_1^2 + \sigma_2^2}$$

3.3 辨識卡爾曼增益結構

對 μ_{post} 做代數重構，從「先驗 μ_1 + 修正量」的角度改寫：

第一步：在分子上加減 $(\sigma_1^2 + \sigma_2^2)\mu_1$ ：

$$\mu_{\text{post}} = \frac{(\sigma_1^2 + \sigma_2^2)\mu_1 + \sigma_1^2(\mu_2 - \mu_1) + \sigma_2^2\mu_1 - \sigma_2^2\mu_1}{\sigma_1^2 + \sigma_2^2}$$

化簡：

$$\mu_{\text{post}} = \mu_1 + \frac{\sigma_1^2 (\mu_2 - \mu_1)}{\sigma_1^2 + \sigma_2^2}$$

第二步：定義卡爾曼增益 K ：

$$K \equiv \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2}$$

於是：

$$\mu_{\text{post}} = \mu_1 + K (\mu_2 - \mu_1)$$

同樣地，後驗變異數可用 K 改寫：

$$\sigma_{\text{post}}^2 = \frac{\sigma_1^2 \sigma_2^2}{\sigma_1^2 + \sigma_2^2} = \sigma_1^2 \cdot \frac{\sigma_2^2}{\sigma_1^2 + \sigma_2^2} = \sigma_1^2 (1 - K)$$

$$\sigma_{\text{post}}^2 = (1 - K) \sigma_1^2$$

3.4 三個核心等式的誕生

編號	等式	KF 對應
①	$K = \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2}$	卡爾曼增益 (Kalman Gain)
②	$\mu_{\text{post}} = \mu_1 + K(\mu_2 - \mu_1)$	後驗狀態更新
③	$\sigma_{\text{post}}^2 = (1 - K) \sigma_1^2$	後驗協方差更新

等式②的命名： $(\mu_2 - \mu_1)$ 稱為 **新息 (Innovation)**，即量測值與預測值之差。後驗估計 = 先驗預測 + 卡爾曼增益 $\times$ 新息。

4. 幾何直覺：增益的物理意義

4.1 增益的範圍與極端情況

$$K = \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2} \in [0, 1]$$

情境	K 值	後驗均值	物理意義
$\sigma_2^2 \rightarrow 0$ (感測器極精確)	$K \rightarrow 1$	$\mu_{\text{post}} \rightarrow \mu_2$	完全信任量測，拋棄預測
$\sigma_1^2 \rightarrow 0$ (模型極精確)	$K \rightarrow 0$	$\mu_{\text{post}} \rightarrow \mu_1$	完全信任預測，忽略量測
$\sigma_1^2 = \sigma_2^2$	$K = 0.5$	$\mu_{\text{post}} = \frac{\mu_1 + \mu_2}{2}$	兩者各佔一半，取中點

4.2 不確定性在融合後必然縮小

由 $\sigma_{\text{post}}^2 = (1 - K)\sigma_1^2$ 且 $0 \leq K \leq 1$ ：

$$\sigma_{\text{post}}^2 \leq \sigma_1^2 \quad \text{且} \quad \sigma_{\text{post}}^2 \leq \sigma_2^2$$

融合後的不確定性永遠小於兩個輸入中的任何一個。

可以直接驗證 $\sigma_{\text{post}}^2 \leq \sigma_2^2$ ：

$$\sigma_{\text{post}}^2 = \frac{\sigma_1^2 \sigma_2^2}{\sigma_1^2 + \sigma_2^2} = \sigma_2^2 \cdot \underbrace{\frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2}}_{=K \leq 1} \leq \sigma_2^2 \quad \checkmark$$

4.3 精度 (Precision) 的加法視角

定義精度 (Precision) 為變異數的倒數 $\lambda = 1/\sigma^2$ ，則兩高斯融合等同於精度相加：

$$\lambda_{\text{post}} = \lambda_1 + \lambda_2$$

$$\frac{1}{\sigma_{\text{post}}^2} = \frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}$$

這與電阻並聯公式完全同構：兩個不確定性來源「並聯」後，整體精度提高。

5. 推廣到多維矩陣形式

5.1 為何需要觀測矩陣 $\mathbf{H}$

純量情況隱含了「狀態空間 = 量測空間（均為 1 維）」的假設。實際系統中：

- 狀態向量 $\mathbf{x} \in \mathbb{R}^n$ （例如位置、速度、偏差， $n = 15$ ）
- 量測向量 $\mathbf{z} \in \mathbb{R}^p$ （例如 GPS 位置， $p = 3$ ）
- 通常 $p < n$ ，無法直接比較

觀測矩陣 $\mathbf{H} \in \mathbb{R}^{p \times n}$ 的作用是將狀態 **投影** 到量測空間：

$$\mathbf{z} = \mathbf{H} \mathbf{x} + \mathbf{v}, \quad \mathbf{v} \sim \mathcal{N}(\mathbf{0}, \mathbf{R})$$

5.2 多維高斯乘積的設定

先驗（預測後）：

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x}; \hat{\mathbf{x}}_{k|k-1}, \mathbf{P}_{k|k-1})$$

量測似然（以 $\mathbf{x}$ 為自變數）：

$$p(\mathbf{z} | \mathbf{x}) = \mathcal{N}(\mathbf{z}; \mathbf{H}\mathbf{x}, \mathbf{R}) \propto \exp\left(-\frac{1}{2}(\mathbf{z} - \mathbf{H}\mathbf{x})^\top \mathbf{R}^{-1}(\mathbf{z} - \mathbf{H}\mathbf{x})\right)$$

後驗正比於兩者之乘積，指數部分相加：

$$-\frac{1}{2} \underbrace{(\mathbf{x} - \hat{\mathbf{x}})^\top \mathbf{P}^{-1}(\mathbf{x} - \hat{\mathbf{x}})}_{\text{先驗項}} - \frac{1}{2} \underbrace{(\mathbf{z} - \mathbf{H}\mathbf{x})^\top \mathbf{R}^{-1}(\mathbf{z} - \mathbf{H}\mathbf{x})}_{\text{似然項}}$$

（以下省略下標 $k|k-1$ ，以 $\hat{\mathbf{x}}, \mathbf{P}$ 代表先驗參數）

5.3 多維配方

展開並收集 $\mathbf{x}$ 各次冪：

$$\text{二次項 (精度矩陣)}: \quad \mathbf{P}^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H}$$

$$\text{一次項 (精度加權均值)}: \quad \mathbf{P}^{-1} \hat{\mathbf{x}} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{z}$$

後驗精度矩陣 (後驗協方差的逆)：

$$\mathbf{P}_{\text{post}}^{-1} = \mathbf{P}^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H}$$

後驗均值 (解線性方程式)：

$$\hat{\mathbf{x}}_{\text{post}} = \mathbf{P}_{\text{post}} \left(\mathbf{P}^{-1} \hat{\mathbf{x}} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{z} \right)$$

5.4 利用矩陣求逆引理化簡

直接使用後驗精度矩陣計算協方差，需要對 $n \times n$ 矩陣求逆。對 $n \gg p$ 的情況 (狀態維度遠大於量測維度) 計算代價高。

使用矩陣求逆引理 (Woodbury Identity / Sherman-Morrison-Woodbury)：

$$(\mathbf{A} + \mathbf{UCV})^{-1} = \mathbf{A}^{-1} - \mathbf{A}^{-1} \mathbf{U} (\mathbf{C}^{-1} + \mathbf{VA}^{-1} \mathbf{U})^{-1} \mathbf{VA}^{-1}$$

令 $\mathbf{A} = \mathbf{P}^{-1}$ ， $\mathbf{U} = \mathbf{H}^\top$ ， $\mathbf{C} = \mathbf{R}^{-1}$ ， $\mathbf{V} = \mathbf{H}$ ：

$$\mathbf{P}_{\text{post}} = (\mathbf{P}^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})^{-1} = \mathbf{P} - \mathbf{PH}^\top (\mathbf{HPH}^\top + \mathbf{R})^{-1} \mathbf{HP}$$

定義卡爾曼增益矩陣：

$$\boxed{\mathbf{K} \equiv \mathbf{PH}^\top (\mathbf{HPH}^\top + \mathbf{R})^{-1}}$$

則後驗協方差化簡為：

$$\mathbf{P}_{\text{post}} = \mathbf{P} - \mathbf{KHP} = (\mathbf{I} - \mathbf{KH}) \mathbf{P}$$

5.5 後驗均值的推導

將 $\mathbf{P}_{\text{post}}$ 代入後驗均值的表達式：

$$\begin{aligned}\hat{\mathbf{x}}_{\text{post}} &= \mathbf{P}_{\text{post}}(\mathbf{P}^{-1}\hat{\mathbf{x}} + \mathbf{H}^\top \mathbf{R}^{-1}\mathbf{z}) \\ &= (\mathbf{I} - \mathbf{KH})\mathbf{P} \cdot \mathbf{P}^{-1}\hat{\mathbf{x}} + (\mathbf{I} - \mathbf{KH})\mathbf{P} \mathbf{H}^\top \mathbf{R}^{-1}\mathbf{z} \\ &= (\mathbf{I} - \mathbf{KH})\hat{\mathbf{x}} + (\mathbf{PH}^\top - \mathbf{KHPH}^\top)\mathbf{R}^{-1}\mathbf{z}\end{aligned}$$

注意到 $\mathbf{K}(\mathbf{HPH}^\top + \mathbf{R}) = \mathbf{PH}^\top$ ，因此：

$$\mathbf{PH}^\top - \mathbf{KHPH}^\top = \mathbf{KR}$$

代入：

$$\hat{\mathbf{x}}_{\text{post}} = (\mathbf{I} - \mathbf{KH})\hat{\mathbf{x}} + \mathbf{KRR}^{-1}\mathbf{z} = \hat{\mathbf{x}} - \mathbf{KH}\hat{\mathbf{x}} + \mathbf{Kz}$$

$$\hat{\mathbf{x}}_{\text{post}} = \hat{\mathbf{x}} + \mathbf{K} \underbrace{(\mathbf{z} - \mathbf{H}\hat{\mathbf{x}})}_{\text{新息 } \tilde{\mathbf{y}}}$$

5.6 對應關係：純量 vs 矩陣

純量符號	矩陣符號	維度	物理角色
σ_1^2	$\mathbf{P}_{k k-1}$	$n \times n$	先驗誤差協方差
σ_2^2	$\mathbf{R}_k$	$p \times p$	量測雜訊協方差
1 (純量單位映射)	$\mathbf{H}_k$	$p \times n$	狀態→量測空間的映射
$\sigma_1^2 + \sigma_2^2$	$\mathbf{S}_k = \mathbf{HPH}^\top + \mathbf{R}$	$p \times p$	新息協方差 (在量測空間中)
$\frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2}$	$\mathbf{PH}^\top \mathbf{S}^{-1}$	$n \times p$	卡爾曼增益矩陣
$\mu_2 - \mu_1$	$\mathbf{z} - \mathbf{H}\hat{\mathbf{x}}$	$p \times 1$	新息向量
$1 - K$	$\mathbf{I} - \mathbf{KH}$	$n \times n$	增益補矩陣

$\mathbf{H}^\top$ 的幾何意義：純量中「除以 $\sigma_1^2 + \sigma_2^2$ 」的操作直接在同一空間進行。多維時，先驗協方差 $\mathbf{P}$ 在狀態空間，而新息協方差 $\mathbf{S}$ 在量測空間， $\mathbf{H}^\top$ 的作用是將量測空間的修正量「拉回」狀態空間，完成不同維度之間的橋接。

6. 最小化跡推導（變分法驗證）

上一節用貝氏推導的方式得到了卡爾曼增益。這節用另一條路——**最優化**——來得到相同結果，作為驗證。

6.1 目標函數

定義後驗估計誤差：

$$\mathbf{e} = \mathbf{x} - \hat{\mathbf{x}}_{\text{post}}$$

後驗協方差：

$$\mathbf{P}_{\text{post}}(\mathbf{K}) = E[\mathbf{e} \mathbf{e}^\top]$$

最優化目標：選擇 $\mathbf{K}$ 使得後驗協方差矩陣的跡最小：

$$\min_{\mathbf{K}} J(\mathbf{K}) = \text{tr}(\mathbf{P}_{\text{post}}(\mathbf{K})) = \sum_{i=1}^n \text{Var}(e_i)$$

最小化跡等同於最小化估計誤差的總變異數（均方誤差之和）。

6.2 建立 $\mathbf{P}_{\text{post}}$ 的表達式

設更新公式為 $\hat{\mathbf{x}}_{\text{post}} = \hat{\mathbf{x}} + \mathbf{K}(\mathbf{z} - \mathbf{H}\hat{\mathbf{x}})$ ，代入 $\mathbf{z} = \mathbf{H}\mathbf{x} + \mathbf{v}$ ：

$$\hat{\mathbf{x}}_{\text{post}} = \hat{\mathbf{x}} + \mathbf{K}(\mathbf{H}\mathbf{x} + \mathbf{v} - \mathbf{H}\hat{\mathbf{x}}) = \hat{\mathbf{x}} + \mathbf{K}\mathbf{H}(\mathbf{x} - \hat{\mathbf{x}}) + \mathbf{K}\mathbf{v}$$

估計誤差：

$$\mathbf{e} = \mathbf{x} - \hat{\mathbf{x}}_{\text{post}} = (\mathbf{I} - \mathbf{K}\mathbf{H})(\mathbf{x} - \hat{\mathbf{x}}) - \mathbf{K}\mathbf{v}$$

$$= (\mathbf{I} - \mathbf{K}\mathbf{H}) \mathbf{e}_{\text{prior}} - \mathbf{K}\mathbf{v}$$

由於先驗誤差 $\mathbf{e}_{\text{prior}}$ 與量測雜訊 $\mathbf{v}$ 獨立，後驗協方差展開為：

$$\mathbf{P}_{\text{post}} = (\mathbf{I} - \mathbf{KH}) \mathbf{P} (\mathbf{I} - \mathbf{KH})^\top + \mathbf{K} \mathbf{R} \mathbf{K}^\top$$

展開（此為 **Joseph Form**，保證對稱正定）：

$$\mathbf{P}_{\text{post}} = \mathbf{P} - \mathbf{KHP} - \mathbf{PH}^\top \mathbf{K}^\top + \mathbf{K}(\mathbf{HPH}^\top + \mathbf{R})\mathbf{K}^\top$$

6.3 對 $\mathbf{K}$ 求偏微分

利用矩陣微分公式：

- $\frac{\partial}{\partial \mathbf{K}} \text{tr}(-\mathbf{KHP}) = -(\mathbf{HP})^\top = -\mathbf{PH}^\top$ （因 $\mathbf{P}$ 對稱）
- $\frac{\partial}{\partial \mathbf{K}} \text{tr}(-\mathbf{PH}^\top \mathbf{K}^\top) = -\mathbf{PH}^\top$
- $\frac{\partial}{\partial \mathbf{K}} \text{tr}(\mathbf{KSK}^\top) = 2\mathbf{KS}$ （其中 $\mathbf{S} = \mathbf{HPH}^\top + \mathbf{R}$ ，對稱）

合計：

$$\frac{\partial \text{tr}(\mathbf{P}_{\text{post}})}{\partial \mathbf{K}} = -2\mathbf{PH}^\top + 2\mathbf{K} \underbrace{(\mathbf{HPH}^\top + \mathbf{R})}_{\mathbf{S}} = \mathbf{0}$$

6.4 求解最優增益

$$2\mathbf{KS} = 2\mathbf{PH}^\top$$

$$\boxed{\mathbf{K} = \mathbf{P} \mathbf{H}^\top \mathbf{S}^{-1} = \mathbf{P} \mathbf{H}^\top (\mathbf{H} \mathbf{P} \mathbf{H}^\top + \mathbf{R})^{-1}}$$

這與貝氏推導（§5.4）的結果完全一致，確認了卡爾曼增益的唯一最優性。

6.5 驗證為最小值（二階條件）

對 $\mathbf{K}$ 的二階導數（Hessian）：

$$\frac{\partial^2 \text{tr}(\mathbf{P}_{\text{post}})}{\partial \mathbf{K}^2} = 2\mathbf{S}$$

由於 $\mathbf{S} = \mathbf{HPH}^\top + \mathbf{R}$ 為正定矩陣（ $\mathbf{P}$ 正定， $\mathbf{R}$ 正定），故 Hessian 正定，確認為 **全域最小值**。

7. 五大 KF 方程式統整

7.1 完整演算法

📌 預測步驟 (Prediction)

① 先驗狀態估計：

$$\hat{\mathbf{x}}_{k|k-1} = \mathbf{F}_{k-1} \hat{\mathbf{x}}_{k-1|k-1} + \mathbf{B}_{k-1} \mathbf{u}_{k-1}$$

② 先驗誤差協方差傳播：

$$\mathbf{P}_{k|k-1} = \mathbf{F}_{k-1} \mathbf{P}_{k-1|k-1} \mathbf{F}_{k-1}^\top + \mathbf{Q}_{k-1}$$

📌 更新步驟 (Update)

③ 卡爾曼增益：

$$\mathbf{K}_k = \mathbf{P}_{k|k-1} \mathbf{H}_k^\top (\mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^\top + \mathbf{R}_k)^{-1}$$

④ 後驗狀態更新：

$$\hat{\mathbf{x}}_{k|k} = \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k (\mathbf{z}_k - \mathbf{H}_k \hat{\mathbf{x}}_{k|k-1})$$

⑤ 後驗協方差更新 (簡化形式)：

$$\mathbf{P}_{k|k} = (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1}$$

⑤' 後驗協方差更新 (Joseph Form, 數值穩定)：


$$\mathbf{P}_{k|k} = (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1} (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k)^\top + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^\top$$

7.2 各方程式之間的邏輯依賴

初始化

$$\hat{\mathbf{x}}_0 |_0, \mathbf{P}_0 |_0$$





8.EKF 的增益：非線性推廣

8.1 非線性系統設定

$$\mathbf{x}_k = f(\mathbf{x}_{k-1}, \mathbf{u}_{k-1}) + \mathbf{w}_{k-1}$$

$$\mathbf{z}_k = h(\mathbf{x}_k) + \mathbf{v}_k$$

8.2 一階泰勒展開（線性化）

在當前估計點 $\hat{\mathbf{x}}_{k|k-1}$ 附近線性化觀測函數：

$$h(\mathbf{x}) \approx h(\hat{\mathbf{x}}_{k|k-1}) + \underbrace{\frac{\partial h}{\partial \mathbf{x}} \bigg|_{\hat{\mathbf{x}}_{k|k-1}}}_{\mathbf{H}_k^J \text{ (雅可比矩陣)}} (\mathbf{x} - \hat{\mathbf{x}}_{k|k-1})$$

8.3 EKF 卡爾曼增益

EKF 的增益公式形式與 KF 完全相同，但 $\mathbf{H}_k$ 換成雅可比矩陣 $\mathbf{H}_k^J$ ：

$$\mathbf{K}_k^{\text{EKF}} = \mathbf{P}_{k|k-1} (\mathbf{H}_k^J)^\top \left(\mathbf{H}_k^J \mathbf{P}_{k|k-1} (\mathbf{H}_k^J)^\top + \mathbf{R}_k \right)^{-1}$$

後驗更新的新息使用**非線性函數**（而非線性近似）：

$$\hat{\mathbf{x}}_{k|k} = \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k^{\text{EKF}} \left(\mathbf{z}_k - h(\hat{\mathbf{x}}_{k|k-1}) \right)$$

8.4 KF 與 EKF 增益計算比較

步驟	KF	EKF
觀測矩陣	$\mathbf{H}$ (常數或時變，但線性)	$\mathbf{H}_k^J = \frac{\partial h}{\partial \mathbf{x}}$
新息協方差 $\mathbf{S}$	$\mathbf{H} \mathbf{P} \mathbf{H}^\top + \mathbf{R}$	$\mathbf{H}_k^J \mathbf{P} (\mathbf{H}_k^J)^\top + \mathbf{R}$
增益 $\mathbf{K}$	$\mathbf{P} \mathbf{H}^\top \mathbf{S}^{-1}$	$\mathbf{P} (\mathbf{H}_k^J)^\top \mathbf{S}^{-1}$
新息 $\tilde{\mathbf{y}}$	$\mathbf{z} - \mathbf{H} \hat{\mathbf{x}}$	$\mathbf{z} - h(\hat{\mathbf{x}})$ (用非線性函數)
協方差更新	$(\mathbf{I} - \mathbf{K} \mathbf{H}) \mathbf{P}$	$(\mathbf{I} - \mathbf{K} \mathbf{H}_k^J) \mathbf{P}$

9. 比較表格：增益在不同情境下的行為

9.1 增益 K 對估計行為的影響

K 值域	對應條件	後驗均值偏向	後驗變異數	適用場景
$K \approx 0$	$\mathbf{R} \gg \mathbf{P}$	幾乎等於先驗 $\hat{\mathbf{x}}$	$\approx \mathbf{P}$ (幾乎不縮小)	感測器極差 (高溫/EMI 環境)
$K \approx 0.5$	$\mathbf{R} \approx \mathbf{H} \mathbf{P} \mathbf{H}^\top$	先驗與量測各半	$\approx \mathbf{P} / 2$	模型與感測器信任度相當
$K \approx \mathbf{H}^{-1}$	$\mathbf{R} \ll \mathbf{P}$	幾乎等於量測 $\mathbf{H}^{-1} \mathbf{z}$	$\approx \mathbf{0}$ (極度縮小)	高精度感測器 (RTK GNSS)

9.2 增益在 KF 家族中的比較

濾波器	增益計算方式	新息計算	線性假設	計算代價
KF	$\mathbf{P} \mathbf{H}^\top (\mathbf{H} \mathbf{P} \mathbf{H}^\top + \mathbf{R})^{-1}$	$\mathbf{z} - \mathbf{H} \hat{\mathbf{x}}$	嚴格線性	$O(n^2 p)$

濾波器	增益計算方式	新息計算	線性假設	計算代價
EKF	$\mathbf{P}\mathbf{H}_J^\top(\mathbf{H}_J\mathbf{P}\mathbf{H}_J^\top + \mathbf{R})^{-1}$	$\mathbf{z} - h(\hat{\mathbf{x}})$	一階線性化	$O(n^2p)$ + 雅可比
IEKF	多次 EKF 迭代直到收斂	同 EKF（多次更新展開點）	迭代線性化	$O(I \cdot n^2p)$
UKF	不顯式計算 $\mathbf{H}$ ，用 Sigma 點統計	Sigma 點傳播	無需線性化	$O((2n + 1) \cdot n^2)$
PF	無增益概念（粒子權重）	每粒子計算似然	無假設	$O(N_p \cdot n)$

9.3 雜訊矩陣 $\mathbf{Q}$ 、 $\mathbf{R}$ 對增益的影響

調整操作	對 $\mathbf{P}_{k k-1}$ 的影響	對 K 的影響	系統行為
增大 $\mathbf{Q}$	$\mathbf{P}$ 增大	K 增大	更信任量測，響應更快
減小 $\mathbf{Q}$	$\mathbf{P}$ 減小	K 減小	更信任模型，估計更平滑
增大 $\mathbf{R}$	$\mathbf{P}$ 不變	K 減小	感測器不確定性增加，更信任預測
減小 $\mathbf{R}$	$\mathbf{P}$ 不變	K 增大	感測器更可信，快速修正
增大 $\mathbf{P}_0$	初始 $\mathbf{P}$ 大	初始 K 大	初期快速收斂到量測

10. 數值範例：一維高度估計

10.1 問題設定

一架無人機以大致固定高度飛行。高度計（氣壓計）有量測雜訊，慣性模型也有積分誤差。

狀態：高度 x_k （單位：公尺）

模型：高度近似不變， $x_k = x_{k-1} + w_{k-1}$ ， $\sigma_w = 0.1\text{ m}$

量測：氣壓計量測， $z_k = x_k + v_k$ ， $\sigma_v = 2.0\text{ m}$

在此純量情況下： $F = 1$ ， $H = 1$ ， $Q = 0.01$ ， $R = 4.0$

10.2 逐步計算

****初始化****： $\hat{x}_{0|0} = 100\text{ m}$ ， $P_{0|0} = 10.0$ （初始不確定性大）

第1步（ $k = 1$ ），收到量測 $z_1 = 98.5\text{ m}$ ：

預測：

$$\hat{x}_{1|0} = 1 \cdot 100 = 100\text{ m}$$

$$P_{1|0} = 1 \cdot 10.0 \cdot 1 + 0.01 = 10.01$$

計算增益：

$$K_1 = \frac{10.01}{10.01 + 4.0} = \frac{10.01}{14.01} \approx 0.714$$

新息：

$$\tilde{y}_1 = 98.5 - 100 = -1.5 \text{ m}$$

後驗更新：

$$\hat{x}_{1|1} = 100 + 0.714 \times (-1.5) = 100 - 1.071 = 98.929 \text{ m}$$

$$P_{1|1} = (1 - 0.714) \times 10.01 = 0.286 \times 10.01 = 2.863$$

第2步 ($k = 2$)，收到量測 $z_2 = 99.2 \text{ m}$ ：

預測：

$$\hat{x}_{2|1} = 98.929 \text{ m}, \quad P_{2|1} = 2.863 + 0.01 = 2.873$$

計算增益（注意 P 已大幅縮小）：

$$K_2 = \frac{2.873}{2.873 + 4.0} = \frac{2.873}{6.873} \approx 0.418$$

新息：

$$\tilde{y}_2 = 99.2 - 98.929 = 0.271 \text{ m}$$

後驗更新：

$$\hat{x}_{2|2} = 98.929 + 0.418 \times 0.271 = 99.042 \text{ m}$$

$$P_{2|2} = (1 - 0.418) \times 2.873 = 1.672$$

趨勢觀察：

步驟	K	P	說明
$k = 0$	—	10.00	初始，高度不確定
$k = 1$	0.714	2.863	K 大，大幅信任量測， P 驟降
$k = 2$	0.418	1.672	K 縮小，模型信心提升
$k \rightarrow \infty$	$K_\infty \approx 0.024$	$P_\infty \approx 0.096$	穩態增益， P 趨於定值

穩態卡爾曼增益 (令 $P_{k|k-1} = P_\infty + Q$ ，解代數 Riccati 方程)：

$$P_\infty = \frac{Q}{2} + \sqrt{\frac{Q^2}{4} + QR} = \frac{0.01}{2} + \sqrt{\frac{0.01^2}{4} + 0.01 \times 4} \approx 0.195 \text{ m}^2$$

$$K_\infty = \frac{P_\infty + Q}{P_\infty + Q + R} \approx \frac{0.205}{4.205} \approx 0.049$$

穩態時，每次量測只修正估計值的約 4.9%，其餘 95.1% 由模型預測決定，反映出氣壓計相對模型不確定性高的特性。

總結：推導路徑圖

貝氏定理

$p(x|z) \propto p(x) \cdot p(z|x)$

↓ 高斯假設

▼

兩高斯相乘

$\exp[-(x-\mu_1)^2/2\sigma_1^2 - (x-\mu_2)^2/2\sigma_2^2]$

↓ 指數相加，配方

▼

後驗仍為高斯： $N(\mu_{\text{post}}, \sigma^2_{\text{post}})$

|
| 代數重構



$\mu_{\text{post}} = \mu_1 + K(\mu_2 - \mu_1)$ ← 卡爾曼更新公式
 $\sigma^2_{\text{post}} = (1-K)\sigma_1^2$ ← 協方差更新公式
 $K = \sigma_1^2 / (\sigma_1^2 + \sigma_2^2)$ ← 純量卡爾曼增益

|
| 多維推廣 (矩陣求逆引理)
| + 最優化驗證 (最小化 $\text{tr}(P)$)



$K = P H^T (H P H^T + R)^{-1}$ ← 矩陣卡爾曼增益 (KF)

|
| 雅可比線性化



$K = P H_J^T (H_J P H_J^T + R)^{-1}$ ← 矩陣卡爾曼增益 (EKF)